


REDES NEURONALES ARTIFICIALES

Introducción

Jesús Alfonso López
jalopez@uao.edu.co



Introducción



Conjunto de elementos de procesamiento que emulan algunas características de funcionamiento del cerebro humano





Motivación y Origen


[1]



[2]




[3]





La Neurona Biológica

Aspectos funcionales de una neurona biológica:

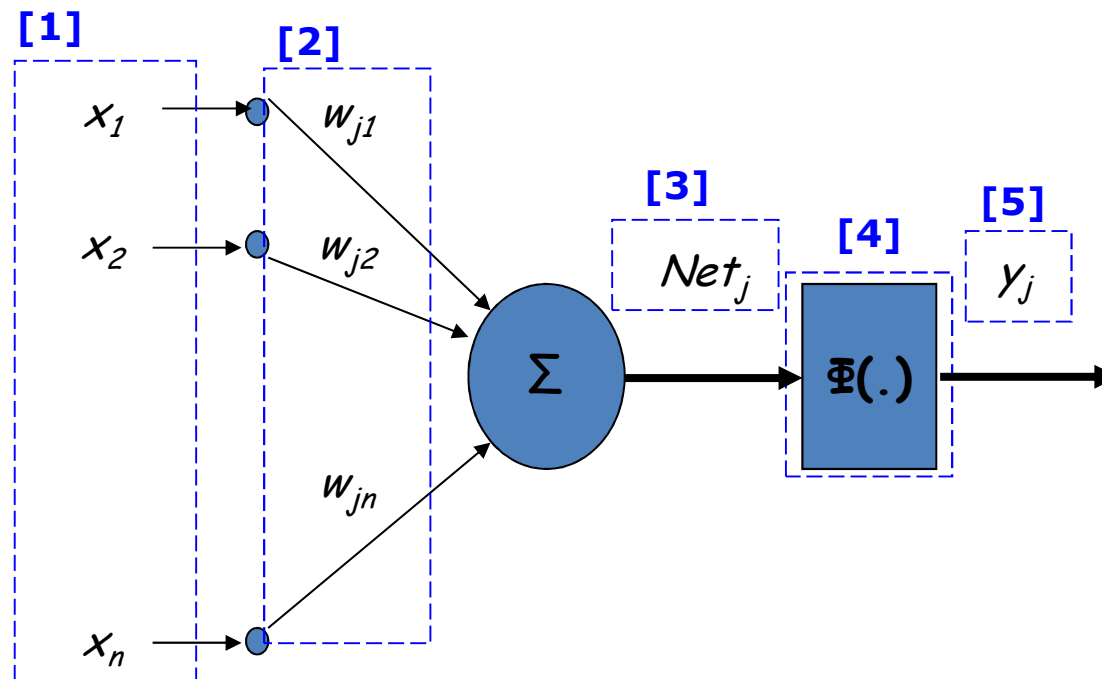


1. Los elementos de proceso (neuronas) reciben las señales de entrada
2. Las señales pueden ser modificadas por los pesos sinápticos
3. Los elementos de proceso suman las entradas afectadas por las sinápsis
4. Bajo una circunstancia apropiada la neurona transmite una señal de salida
5. La salida del elemento de proceso puede ir a muchas neuronas



La Neurona Artificial

Modelo propuesto a partir de la neurona biológica:





Pesos Sinápticos

La matriz de pesos sinápticos es el parámetro que se utiliza para representar la conexión entre las neuronas, de manera similar a lo que hace la sinapsis en las neuronas biológicas. Esta matriz será fundamental en el proceso de aprendizaje, como veremos más adelante.

Representaremos el término genérico de esta matriz así:

$$w_{ij}$$

Este término representa el valor de la conexión que va a la neurona *i*-ésima, proveniente de la neurona *j*-ésima.





Entrada Neta

La magnitud que denominamos *Neta* representa la entrada total de información o estímulo que recibe una neurona, proveniente de fuentes externas o de otras neuronas a las cuales está conectada.


Este valor lo evaluamos en la función de activación para generar la salida total de la neurona, tal como lo vemos en la expresión que sigue:

$$Neta_j = \sum_{i=1}^n w_{ji} x_i + b_j$$
$$y_j = \Phi(Neta_j)$$





Función de Activación Lineal



$$f(x) = x$$

Con este tipo de función de activación la salida es continua e igual al estímulo de entrada o Entrada Neta de la red, como la hemos denominado.


En las neuronas de entrada, naturalmente, seleccionaremos este tipo de función de activación puesto que no hay ningún tipo de procesamiento.

Suele utilizarse también en la capa de salida cuando queremos justamente una salida continua e igual a los estímulos provenientes de la capa oculta. Eventualmente la utilizaremos en las capas ocultas.





Función de Activación Tipo Escalón



$$f(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases}$$


Con este tipo de función de activación la salida no es continua y tiene dos valores, 1: si la entrada neta a la neurona es mayor o igual a cero; 0: si la entrada neta es menor que cero.

Este tipo de función de activación se utiliza en la capa de salida cuando éstas son de naturaleza discontinua. No tiene mucho sentido utilizarla en las redes multicapa y hasta ahora no conocemos aplicación alguna donde se haya hecho. Incluso veremos como, para ciertos algoritmos de aprendizaje, no se debe definir este tipo de función de activación en sus capas.





Función de Activación Bipolar



$$f(x) = \begin{cases} 1 & x \geq 0 \\ -1 & x < 0 \end{cases}$$


Con este tipo de función de activación la salida no es continua y tiene dos valores, 1: si la entrada neta a la neurona es mayor o igual a cero; -1: si la entrada neta es menor que cero.

Este tipo de función de activación se utiliza en la capa de salida cuando éstas son de naturaleza discontinua. No tiene mucho sentido utilizarla en las redes multicapa y hasta ahora no conocemos aplicación alguna donde se haya hecho. Incluso veremos como, para ciertos algoritmos de aprendizaje, no se debe definir este tipo de función de activación en sus capas.





Función de Activación Sigmoidal



$$f(x) = \frac{1}{1 + e^{-\sigma x}}$$

Con este tipo de función de activación la salida es continua y la podemos ver como una función tipo escalón pero suavizada, de tal manera que la transición entre el cero y el uno, no sea brusca o discontinua.


La ventaja significativa que le da este tipo de función a una neurona o red neuronal, es que al procesamiento le propicia características de no linealidad, por lo que la aplicaremos en algoritmos de aprendizaje más complejos que los permitidos por neuronas cuya función de activación es del tipo escalón.

Puede utilizarse tanto en las capas ocultas como en la de salida. En las capas ocultas ganaremos no linealidad y en la de salida, la usaremos cuando la naturaleza de ésta sea similar a la binaria o escalón, pero requiramos que la magnitud sea continua para realizar algún tipo de pos-procesamiento.





Función de Activación TangenteSigmoidal



$$f(x) = \frac{2}{1 + e^{-\alpha x}} - 1$$

Con este tipo de función de activación la salida es continua y la podemos ver como una función tipo escalón pero suavizada, de tal manera que la transición entre el cero y el uno, no sea brusca o discontinua.

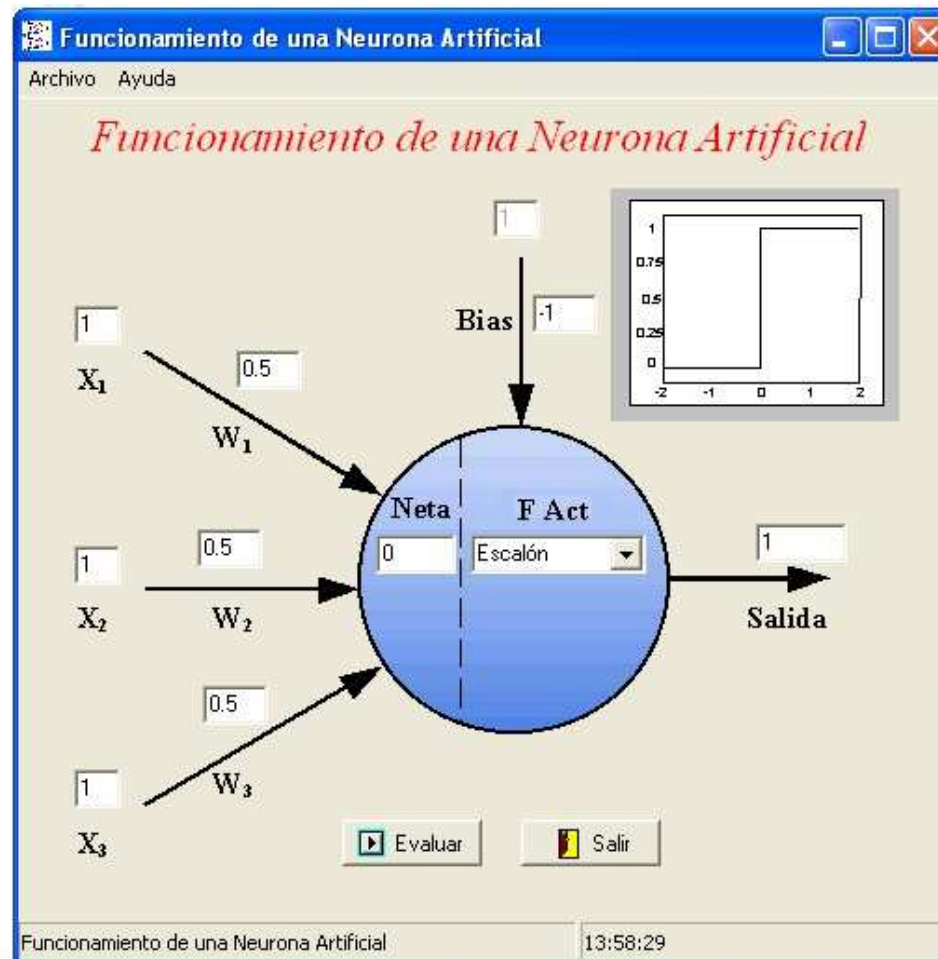
La ventaja significativa que le da este tipo de función a una neurona o red neuronal, es que al procesamiento le propicia características de no linealidad, por lo que la aplicaremos en algoritmos de aprendizaje más complejos que los permitidos por neuronas cuya función de activación es del tipo escalón.

Puede utilizarse tanto en las capas ocultas como en la de salida. En las capas ocultas ganaremos no linealidad y en la de salida, la usaremos cuando la naturaleza de ésta sea similar a la binaria o escalón, pero requiramos que la magnitud sea continua para realizar algún tipo de pos-procesamiento.





Emulación de una Neurona Artificial





Semejanza con el Cerebro

- Emula el funcionamiento del cerebro en dos aspectos:
 - El conocimiento es obtenido por la red a través de un proceso de aprendizaje.
 - Las conexiones entre neuronas conocidas como pesos sinápticos son utilizadas para almacenar dicho conocimiento.
- Las RNA se desarrollan como generalizaciones de modelos matemáticos del conocimiento humano o de la biología neuronal, con base en los siguientes considerandos:
 - Elementos de procesamiento simples (Neuronas)
 - Conectividad
 - Enlaces de conexión con pesos
 - Función de Activación





Algunas Características de las RNA

1. Capacidad de aprendizaje
2. Capacidad de generalización
3. Extraen características esenciales de información irrelevante





Ventajas Significativas

1. Aprendizaje Adaptativo
2. Auto – Organización
3. Tolerancia a Fallos
4. Operación en Tiempo Real





Campos de Aplicación

